

CLASSIFICAÇÃO DE ÁUDIOS COM DEEP LEARNING

- ANÁLISE E IMPLEMENTAÇÃO DE MLP E CNN PARA O
DATASET URBAN SOUND DATA

Alunos

Ana Matilde Ferreira, 202307802
Maria Leonor Carvalho, 202307522

Unidade Curricular


Aprendizagem Computacional II

Professor

Francesco Renna

DATA PRE-PROCESSING AND PREPARATION


Análise Inicial dos Dados - Distribuição dos áudios pelas classes



- A análise inicial do *dataset* revelou um **desequilíbrio significativo entre classes**: as categorias ***car_horn*** (429), ***gun_shot*** (374) e ***siren*** (929) apresentam menos amostras do que as restantes (1000 cada)
- ***Class Imbalance*** compromete o desempenho dos modelos, levando-os a **privilegiar as classes mais representadas** e a **reduzir a capacidade de generalização**
- Solução encontrada: ***Data Augmentation*** nas classes minoritárias

DATA PRE-PROCESSING AND PREPARATION

Data Augmentation dirigido às classes minoritárias - Objetivo



- Transformações aplicadas: ***Time Stretching; Pitch Shifting; Adição de ruído; Temporal Shifting***
- Permite **aumentar a variabilidade dos dados**, tornam o **conjunto de treino mais equilibrado** e contribuem para um **melhor desempenho global**
- Objetivo: Que **todas as classes tenham 1000 ficheiros** de áudio associados

DATA PRE-PROCESSING AND PREPARATION

Data Augmentation - Estratégia utilizada

01

Criar uma **cópia do *dataset***, que incluirá os áudios gerados no processo de *Data Augmentation*, de modo a **manter os dados originais intactos**

02

Criar um **dicionário** onde as **chaves** correspondem às **classes minoritárias** e os **valores** a **listas de caminhos para todos os ficheiros** pertencentes a cada uma dessas classes, de modo a **facilitar a seleção** e o processamento dirigido dos áudios que **necessitam de *augmentation***.

03

Automatização da geração de novos áudios:

- **Seleção aleatória de ficheiros** base dentro de cada classe minoritária
- **Aplicação das transformações** definidas (*Time Stretch*, *Pitch Shift*, Ruído, *Shift*)
- **Criação de múltiplos exemplos** por classe, com nomes de ficheiros únicos

Dataset Original

Cópia +
Dicionário

Seleção aleatória

Transformações

Novo áudio

Transformações

Novo áudio

DATA PRE-PROCESSING AND PREPARATION

Data Augmentation - Estratégia utilizada

04

Distribuição proporcional pelas folds: Garantir que cada fold recebe novos áudios proporcionalmente ao número original de ficheiros da classe

05

Atualização de metadados: Criar um novo CSV, para os metadados augmented, onde cada novo áudio, atualiza o CSV com as suas respetivas informações

Dataset Original

Cópia +
Dicionário

Seleção aleatória

Transformações


Novo áudio

Transformações

Novo áudio

DATA PRE-PROCESSING AND PREPARATION

Nova Análise dos Dados - Distribuição das classes pelos folds



DATA PRE-PROCESSING AND PREPARATION

Uniformização dos Dados

Objetivo

Garantir que todos os áudios têm características consistentes para alimentar os modelos de Deep Learning

Procedimento

01

Uniformizar a Sample Rate: Converter todos os áudios para a mesma taxa de amostragem, de **22.050kHz**, garantindo compatibilidade → obtido a partir do *librosa.resample*

02

Duração Fixa: Ajustar todos os áudios para 4 segundos de duração, permitindo o treino consistente → obtido a partir da **repetição dos áudios até terem exatamente 4 segundos**

03

Normalização da Amplitude: garantir que todos os áudios têm a mesma escala de intensidade (-1 a 1) → obtido a partir do *librosa.util.normalize*



Os dados processados foram armazenados nas novas pastas *audios_4sec*, com apenas os áudios originais, e em *audios_4sec_aug*, que inclui os dados originais e os aumentados

DATA PRE-PROCESSING AND PREPARATION

Uniformização dos Dados

Visualização de um Exemplo

Áudio Original





* No Notebook está disponível a audição do áudio original e do processado

DATA PRE-PROCESSING AND PREPARATION

Uniformização dos Dados

Visualização de um Exemplo

Áudio Processado



* No Notebook está disponível a audição do áudio original e do processado

MLP ARCHITECTURE

Introdução

Objetivo

Classificar os áudios nas suas respectivas classes usando **redes neurais totalmente conectadas**

Motivação

MLPs são eficazes na aprendizagem de **relações não-lineares** em dados estruturados. Permitem capturar **padrões globais** nos features de áudio após o processo de extração de características

Input

Features extraídas do áudio (MFCCs, cromas, mel-spectrograma, tonnetz, etc.) representadas como **vetores unidimensionais**

Output

Probabilidades para cada classe (*softmax*).

MLP - PRÉ-PROCESSAMENTO

Extração das Features

Tipo de features

- **MFCC + delta + delta2**
- **Spectral features** (spectral_centroid, spectral_rolloff, ZCR)
- **Chroma**
- **Mel spectrogram**
- **Tonnetz**

Convertem cada ficheiro áudio num **vetor numérico fixo**, adequado para treinar o modelo MLP.

É verificado a dimensão e integridade dos dados em cada fold, tanto para amostras aumentadas como originais

Função de verificação de integridade dos dados:
check_invalid_values

MLP - ARQUITETURA

Arquitetura do MLP

MLP Model Architecture Defined

Model: "sequential_1287"

Layer (type)	Output Shape	Param #
dense_5156 (Dense)	(None, 128)	11,264
batch_normalization_3855 (BatchNormalization)	(None, 128)	512
dropout_3855 (Dropout)	(None, 128)	0
dense_5157 (Dense)	(None, 64)	8,256
batch_normalization_3856 (BatchNormalization)	(None, 64)	256
dropout_3856 (Dropout)	(None, 64)	0
dense_5158 (Dense)	(None, 32)	2,080
batch_normalization_3857 (BatchNormalization)	(None, 32)	128
dropout_3857 (Dropout)	(None, 32)	0
dense_5159 (Dense)	(None, 10)	330

Total params: 22,826 (89.16 KB)

Trainable params: 22,378 (87.41 KB)

Non-trainable params: 448 (1.75 KB)

- 3 camadas fully connected: 128 → 64 → 32 com blocos Dense + BN + Dropout
 - Permite aprender representações cada vez mais abstratas das features de áudio.
- Uso de:
- BatchNormalization**: estabiliza e acelera o treino, ajustando a escala das features
 - Dropout**: reduz overfitting nas camadas maiores

Esta arquitetura oferece bom equilíbrio entre **capacidade de aprendizagem** das features e **controle de overfitting**, apresentando o melhor desempenho entre as variantes testadas.

MLP - TRAINING STRATEGY

Estratégia de Treino

Estratégia

Fine-Tuning do MLP com Random Search

Hiperparâmetros

- **Número de neurônios por camada**
- **Dropout**
- **Regularização L2**
- **Learning rate**
- **Otimizador (Adam/Nadam)**
- **Batch size**

O ajuste de hiperparâmetros permite ao Random Search explorar diferentes combinações para **equilibrar capacidade de representação, estabilidade do treino e generalização**, garantindo que o MLP aprenda padrões complexos das features de áudio sem sobreajustar os dados.

Random Search explora de forma eficiente o espaço de hiperparâmetros do MLP, encontrando boas combinações sem o custo computacional de testar todas as possibilidades como no Grid Search

MLP - PERFORMANCE EVALUATION

Resultados

 Sem Fine-tuning com Random Search

1º treino

 Média: **63.59%**

 Desvio: **4.08 %**

 Com Fine-tuning com Random Search

2º treino

 Média: **65.37%**

 Desvio: **4.08 %**

escolhido

DeepFool

Gera perturbações mínimas que fazem o modelo classificar incorretamente uma amostra

Métricas avaliadas

Success Rate: proporção de amostras que foram enganadas pelo ataque.

Perturbation Norm: magnitude média da perturbação necessária para enganar o modelo.

Resultados

Success Rate: 1.000 → todas as amostras foram classificadas incorretamente com pequenas perturbações.

Perturbation Norm: 7.058 ± 7.500 → variabilidade alta na magnitude das perturbações.

CNN

Introdução

Objetivo

Classificar os áudios nas suas respectivas classes usando **redes convolucionais 2D**

Motivação

CNNs são eficazes na **extração de padrões espaciais e temporais de espectrogramas**. Permitem **capturar as *features* locais**, úteis em **dados de áudio transformados em imagens (espectrogramas)**

Input

Espectrogramas ou **MFCCs** (as CNNs exigem inputs de tamanho fixo e distribuição estável)

Output

Probabilidades para cada classe (*softmax*).

CNN - PRÉ-PROCESSAMENTO

Extração das Features

MFCC + Deltas + Delta-Deltas

Características perceptuais

- 25 MFCC
- 25 Deltas (velocidade)
- 25 Delta-Deltas (aceleração)
- Janela FFT = 512
- hop_length = 256

Verificação da Integridade dos Dados:
→ 1000 amostras Shape (75, 345)
Formato de Input: (75, 345, 1)

Mel Spectrogram

Padrões espectrais brutos

- 128 Bandas de Mel
- Janela FFT = 512
- hop_length = 256

Verificação da Integridade dos Dados:
1000 amostras por Shape (128, 173)
Formato de Input: (128, 173, 1)

É verificado que todas as amostras têm o mesmo formato, logo são adequadas como input numa CNN 2D


`analyze_mfcc_dimensions` e `analyze_melSpect_dimensions`

CNN - PRÉ-PROCESSAMENTO

Visualização das Features

MFCC + Deltas + Delta-Deltas

MFCC - Ficheiro: 34771-3-0-14.wav de fold5_4sec
Classe: dog_bark




CNN - PRÉ-PROCESSAMENTO

Visualização das Features

Mel Spectrogram

Mel Spectrogram - Ficheiro: 77751-4-8-0.wav de fold2_4sec
Classe: drilling



CNN - ARQUITETURA 2D

Arquitetura da CNN com MFCC como input

CNN Model Architecture Defined with MFCC as input
Model: "sequential"

Layer (type)	Output Shape	Param #
conv2d (Conv2D)	(None, 75, 345, 32)	320
batch_normalization (BatchNormalization)	(None, 75, 345, 32)	128
max_pooling2d (MaxPooling2D)	(None, 37, 172, 32)	0
conv2d_1 (Conv2D)	(None, 37, 172, 64)	18,496
batch_normalization_1 (BatchNormalization)	(None, 37, 172, 64)	256
max_pooling2d_1 (MaxPooling2D)	(None, 18, 86, 64)	0
conv2d_2 (Conv2D)	(None, 18, 86, 128)	73,856
batch_normalization_2 (BatchNormalization)	(None, 18, 86, 128)	512
max_pooling2d_2 (MaxPooling2D)	(None, 9, 43, 128)	0
conv2d_3 (Conv2D)	(None, 9, 43, 256)	295,168
batch_normalization_3 (BatchNormalization)	(None, 9, 43, 256)	1,024
max_pooling2d_3 (MaxPooling2D)	(None, 4, 21, 256)	0
global_average_pooling2d (GlobalAveragePooling2D)	(None, 256)	0
dense (Dense)	(None, 256)	65,792
dropout (Dropout)	(None, 256)	0
dense_1 (Dense)	(None, 10)	2,570

Total params: 458,122 (1.75 MB)
Trainable params: 457,162 (1.74 MB)
Non-trainable params: 960 (3.75 KB)

- Design progressivo: 32 → 64 → 128 → 256 com blocos Conv2D + BN + MaxPool
- Permite aprender padrões tempo-frequência cada vez mais complexos
- Uso de:
 - **GlobalAveragePooling**: reduzir parâmetros
 - **Dense final**: 256 unidades com *Dropout*

Esta arquitetura oferece bom equilíbrio entre **capacidade representativa** e **controle de overfitting**, tendo mostrado o melhor desempenho entre as variantes testadas.

CNN - TRAINING STRATAGY

Processo de Escolhas

1 Decisão: **Com ou Sem Data Augmentation**

EarlyStopping Patience = 5

Input - MFCC

Sem Data Augmentation - MFCC

● Média: **64.15 %**

● Desvio: **6.39 %**

Com Data Augmentation - MFCC

● Média: **66.37 %**

● Desvio: **4.38 %**

Escolhido

2 Decisão: **MFCC ou Mel Spectrogram**

EarlyStopping Patience = 5

MFCC

● Média: **66.37 %**

● Desvio: **4.38 %**

Mel Spectrogram

● Média: **72.57 %**

● Desvio: **4.32 %**

Escolhido

CNN - TRAINING STRATAGY

Processo de Escolhas

3 Decisão: **Patience de 5 ou 10**

Sem Data Augmentation - MFCC

- Média: **72.57 %**
- Desvio: **4.32 %**

Com Data Augmentation - MFCC

- Média: **76.18 %**
- Desvio: **3.36 %**

Escolhido

CNN - TRAINING STRATAGY

Escolhas Finais

Hiperparâmetros

- Otimizador: **Adam (lr = 1e-4)**
- Batch Size: **32**
- Loss: **Categorical Crossentropy**

Normalização

- Cada fold é normalizado com média e desvio padrão

Regularização

- **Data Augmentation**
- **Dropout de 0.3**
- **EarlyStopping com patience 10**
- **ReduceLROPlateau**

Input

- **Mel Spectrograms**

CNN - PERFORMANCE EVALUATION

Resultados

Os melhores resultados de performance obtidos com ***Mel Spectograms***, ***Data Augmentation*** e **EarlyStopping** com **Patience = 10** foram:

● Accuracy Média: **76.18 %**

● Desvio Padrão: **3.36 %**

Nota

Apesar de o resultado final ter sido melhor apenas com Data Augmentation como Training Strategy foram implementadas outras alternativas que serão apresentadas de seguida

CNN - TRAINING STRATAGY

Outras Alternativas

1 Combined Feature Training with MFCC + Mel Spectrogram

● Média: **71.37 %**

● Desvio: **5.20 %**

Possíveis Causas da performance limitada

- Modelo com **pouca profundidade** para explorar todas as features
- **Input dimension mismatch**, visto que pode exigir regularizações mais fortes
- **EarlyStopping** pode estar com patience baixa para explorar todas as features

2 Transfer Learning com EfficientNet

● Média: **71.52 %**

● Desvio: **5.60 %**

Possíveis Causas da performance limitada

- Provavelmente devido à **diferença de domínio entre imagens e espectrogramas de áudio**